

Prediction Model

ID/X Partners - Data Scientist

Presented by
Muhammad Faris Akbar



Muhammad Faris Akbar

Fresh Graduate

Lulusan Teknik Informatika dari Universitas
Ahmad Dahlan dengan IPK 3.77. Memiliki
pengalaman sebagai Asisten Peneliti, Asisten
Dosen, Machine Learning Engineer dan
Project Manager



Karawang



mfarfaris@gmail.com



<https://www.linkedin.com/in/m-faris-akbar-/>

***notes: just a sample page**

About Company

id/x partners (IDX Consulting) adalah perusahaan konsultan dan penyedia solusi teknologi informasi yang berfokus pada layanan data analitik, keputusan, dan manajemen risiko, didirikan pada tahun 2002 oleh mantan bankir dan konsultan manajemen berpengalaman di bidang perbankan dan manajemen kinerja. Perusahaan ini membantu institusi keuangan dan lainnya untuk mengoptimalkan profitabilitas portofolio dan proses bisnis menggunakan solusi cloud-native, AI/ML, otomatisasi, analitik, dan pemodelan prediktif.



Project Portfolio

Project Description

Credit risk prediction model merupakan sebuah project machine learning yang bertujuan untuk mengembangkan model prediksi risiko kredit dari perusahaan pemberi pinjaman (multifinance). Tujuan dari project ini adalah untuk meningkatkan keakuratan dalam menilai dan mengelola risiko kredit.

Problem Statement

Sebuah perusahaan pemberi pinjaman (multifinance) ingin mengembangkan model machine learning yang dapat meningkatkan keakuratan dalam menilai dan mengelola risiko kredit. Dimana, kesalahan dalam pengambilan keputusan risiko kredit dapat berdampak pada kerugian finansial bagi perusahaan.

1. Data Overview

id	member_id	loan_amnt	funded_amnt	funded_amnt_inv	term	int_rate	installment	grade	sub_grade	emp_title	emp_length	home_ownership	annual_inc	verification_status	issue_d	loan_status	pymnt_p
0	1077501	1296599	5000	5000	4975.0	36 months	10.65	162.87	B	B2	NaN	10+ years	RENT	24000.0	Verified	Dec-11	Fully Paid
1	1077430	1314167	2500	2500	2500.0	60 months	15.27	59.83	C	C4	Ryder	< 1 year	RENT	30000.0	Source Verified	Dec-11	Charged Off
2	1077175	1313524	2400	2400	2400.0	36 months	15.96	84.33	C	C5	NaN	10+ years	RENT	12252.0	Not Verified	Dec-11	Fully Paid
3	1076863	1277178	10000	10000	10000.0	36 months	13.49	339.31	C	C1	AIR RESOURCES BOARD	10+ years	RENT	49200.0	Source Verified	Dec-11	Fully Paid
4	1075358	1311748	3000	3000	3000.0	60 months	12.69	67.79	B	B5	University Medical Group	1 year	RENT	80000.0	Source Verified	Dec-11	Current
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
466280	8598660	1440975	18400	18400	18400.0	60 months	14.47	432.64	C	C2	Financial Advisor	4 years	MORTGAGE	110000.0	Source Verified	Jan-14	Current
466281	9684700	11536848	22000	22000	22000.0	60 months	19.97	582.50	D	D5	Chief of Interpretation (Park Ranger)	10+ years	MORTGAGE	78000.0	Verified	Jan-14	Charged Off
466282	9584776	11436914	20700	20700	20700.0	60 months	16.99	514.34	D	D1	patrol	7 years	MORTGAGE	46000.0	Verified	Jan-14	Current
466283	9604874	11457002	2000	2000	2000.0	36 months	7.90	62.59	A	A4	Server Engineer	3 years	OWN	83000.0	Verified	Jan-14	Fully Paid

2. Data Understanding

Data Information

Berdasarkan hasil pemeriksaan, terdapat 46 data dengan tipe float64, 6 data dengan tipe int64 dan 22 data dengan tipe object. Namun beberapa tipe data pada data ini belum sesuai sehingga perlu dilakukan formating.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 466285 entries, 0 to 466284
Data columns (total 74 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   id                                     466285 non-null  int64
1   member_id                             466285 non-null  int64
2   loan_amnt                             466285 non-null  int64
3   funded_amnt                           466285 non-null  int64
4   funded_amnt_inv                       466285 non-null  float64
5   term                                  466285 non-null  object
6   int_rate                              466285 non-null  float64
7   installment                           466285 non-null  float64
8   grade                                 466285 non-null  object
9   sub_grade                             466285 non-null  object
10  emp_title                             438697 non-null  object
11  emp_length                             445277 non-null  object
12  home_ownership                        466285 non-null  object
13  annual_inc                             466281 non-null  float64
14  verification_status                  466285 non-null  object
15  issue_d                                466285 non-null  object
16  loan_status                           466285 non-null  object
17  pymnt_plan                            466285 non-null  object
18  url                                    466285 non-null  object
19  desc                                  125981 non-null  object
20  purpose                               466285 non-null  object
21  title                                 466264 non-null  object
22  zip_code                              466285 non-null  object
23  addr_state                            466285 non-null  object
24  dti                                    466285 non-null  float64
25  delinq_2yrs                           466256 non-null  float64
26  earliest_cr_line                       466256 non-null  object
27  inq_last_6mths                         466256 non-null  float64
28  mths_since_last_delinq                 215934 non-null  float64
29  mths_since_last_record                 62638 non-null  float64
30  open_acc                               466256 non-null  float64
31  pub_rec                                466256 non-null  float64
32  revol_bal                              466285 non-null  int64
33  revol_util                             465945 non-null  float64
34  total_acc                              466256 non-null  float64
35  initial_list_status                    466285 non-null  object
36  out_prncp                              466285 non-null  float64
37  out_prncp_inv                          466285 non-null  float64
38  total_pymnt                            466285 non-null  float64
39  total_pymnt_inv                       466285 non-null  float64
40  total_rec_prncp                        466285 non-null  float64
41  total_rec_int                          466285 non-null  float64
42  total_rec_late_fee                     466285 non-null  float64
43  recoveries                             466285 non-null  float64
44  collection_recovery_fee                466285 non-null  float64
45  last_pymnt_d                           465909 non-null  object
46  last_pymnt_amnt                       466285 non-null  float64
47  next_pymnt_d                           239071 non-null  object
48  last_credit_pull_d                     466243 non-null  object
49  collections_12_mths_ex_med             466140 non-null  float64
```


2. Data Understanding

Analisis Deskriptif

Pada masing-masing kolom akan dilakukan analisis deskriptif untuk melihat persebaran dari data. Dimana persebaran ini mencakup, mean, std deviasi, kuartil, dan sebagainya

	id	member_id	loan_amnt	funded_amnt	funded_amnt_inv	int_rate	installment	annual_inc	dti	delinq_2yrs	inq_last_6mths	mths_since_last_delinq	mths_since_last_record
count	4.662850e+05	4.662850e+05	466285.000000	466285.000000	466285.000000	466285.000000	466285.000000	4.662810e+05	466285.000000	466256.000000	466256.000000	215894.000000	62638.000000
mean	1.307973e+07	1.459766e+07	14317.277577	14291.801044	14222.329888	13.829236	432.061201	7.327738e+04	17.218758	0.284678	0.804745	34.104430	74.306012
std	1.089371e+07	1.168237e+07	8286.509164	8274.371300	8297.637788	4.357587	243.485550	5.496357e+04	7.851121	0.797365	1.091598	21.778487	30.357853
min	5.473400e+04	7.047300e+04	500.000000	500.000000	0.000000	5.420000	15.670000	1.896000e+03	0.000000	0.000000	0.000000	0.000000	0.000000
25%	3.639987e+06	4.379705e+06	8000.000000	8000.000000	8000.000000	10.990000	256.690000	4.500000e+04	11.360000	0.000000	0.000000	16.000000	53.000000
50%	1.010790e+07	1.194108e+07	12000.000000	12000.000000	12000.000000	13.660000	379.890000	6.300000e+04	16.870000	0.000000	0.000000	31.000000	76.000000
75%	2.073121e+07	2.300154e+07	20000.000000	20000.000000	19950.000000	16.490000	566.580000	8.896000e+04	22.780000	0.000000	1.000000	49.000000	102.000000
max	3.809811e+07	4.086083e+07	35000.000000	35000.000000	35000.000000	26.060000	1409.990000	7.500000e+06	38.990000	29.000000	33.000000	188.000000	129.000000

3. Data Pre-Processing

Pemeriksaan Nilai NaN

Pemeriksaan nilai missing atau nan dilakukan terhadap keseluruhan kolom, dimana untuk penanganan nilai nan ini sendiri dibagi menggunakan 3 metode, yaitu :

1. Membuang nilai NaN
2. Imputasi nilai
3. Imputasi nilai menggunakan metode MICE

	Jumlah Nilai Missing	Persentase Nilai Missing (%)
open_rv_24m	466285	100.000
inq_fi	466285	100.000
open_rv_12m	466285	100.000
il_util	466285	100.000
mths_since_rcnt_il	466285	100.000
total_bal_il	466285	100.000
open_il_24m	466285	100.000
open_il_12m	466285	100.000
open_il_6m	466285	100.000
open_acc_6m	466285	100.000
dti_joint	466285	100.000
annual_inc_joint	466285	100.000
max_bal_bc	466285	100.000
all_util	466285	100.000
inq_last_12m	466285	100.000
total_cu_tl	466285	100.000
verification_status_joint	466285	100.000
mths_since_last_record	403647	86.567

3. Data Pre-Processing

Pemeriksaan Nilai

Duplicated

1. Melalui pemeriksaan nilai duplikat, tidak ditemukan adanya nilai duplikat pada data

```
visualize_row_with_duplicated(data)
```




Tidak ada data duplikat

3. Data Pre-Processing


Pemeriksaan Nilai Outlier

1. Melalui pemeriksaan nilai duplikat, ditemukan adanya outlier pada data terutama data numeric




3. Exploratory Data Analysis

Tahapan EDA dibagi menjadi 3 bagian, yaitu pemeriksaan informasi dan deskripsi ulang data serta distribusi data



4. Feature Analysis dan Selection

Pada tahapan Feature Analysis dan Selection. Dipilih fitur yang paling penting dan berkorelasi dengan target data. Dilakukan filtering feature yang mungkin bisa menyebabkan bias pada data



5. Data Modeling

Model yang digunakan pada project ini dibagi menjadi 3 yaitu Logistic Regression, Random Forest, and Gradient Boosting

```
# Initialize models
log_reg = LogisticRegression(random_state=42, solver='liblinear')
random_forest = RandomForestClassifier(random_state=42)
gradient_boosting = GradientBoostingClassifier(random_state=42)

# Train models
print("Training Logistic Regression...")
log_reg.fit(X_train_processed, y_train)
print("Logistic Regression trained.")

print("Training Random Forest...")
random_forest.fit(X_train_processed, y_train)
print("Random Forest trained.")

print("Training Gradient Boosting...")
gradient_boosting.fit(X_train_processed, y_train)
print("Gradient Boosting trained.")
```

6. Evaluation

Berdasarkan hasil analisis, didapatkan bahwa random forest merupakan metode dengan evaluasi metrik terbaik, dimana mendapatkan Accuracy 0.95, Precision 0.97, F1-Score 0.80, dan ROC-AUC 0.94.

7. Conclusion

Berdasarkan hasil percobaan, Random Forest merupakan metode dengan hasil evaluasi terbaik dibandingkan dengan Logistic Regression atau Gradient Boosting. Dengan Accuracy 0.95, Precision 0.97, F1-Score 0.80, dan ROC-AUC 0.94.

Thank You



Rakamin
Academy



Logo Company